

Título Sugerido

Análise Arquitetural do Congelamento de Camadas na Mitigação de *Domain Shift* e *Language Shift* em Transformers Multilíngues.

1. Definição do Problema

A implantação de modelos de Processamento de Linguagem Natural (PLN) no mercado brasileiro esbarra no alto custo de rotulação de dados em português. A abordagem de transferência *Zero-Shot Cross-Lingual* promete resolver isso ao treinar o modelo em bases abundantes em inglês e testá-lo diretamente em português. No entanto, em cenários reais de plataformas de e-commerce e aplicativos de logística de entrega, a performance do modelo degrada severamente. O problema central consiste em determinar estruturalmente o que causa essa falha de generalização na rede neural: a alteração do idioma ou a alteração da semântica da tarefa (quando a avaliação deixa de ser sobre as características do produto e passa a ser sobre problemas operacionais de entrega e logística).

2. Pergunta de Pesquisa (Research Question)

"Em tarefas de classificação de sentimentos *Zero-Shot Cross-Lingual*, o congelamento seletivo de pesos (*Layer Freezing*) em arquiteturas Transformer (XLM-R) atua de forma mais eficaz na mitigação da degradação de performance causada pelo *Domain Shift* (avaliações de Produto vs. Logística) ou pelo *Language Shift* (Inglês vs. Português)?"

3. Contexto

O estado da arte em PLN utiliza arquiteturas baseadas em *Self-Attention*, como os Transformers Multilíngues (XLM-RoBERTa, mBERT), que mapeiam palavras de diferentes idiomas para um espaço latente vetorial compartilhado. Estudos de interpretabilidade (*BERTology*) indicam que essas arquiteturas aprendem de forma hierárquica: as camadas iniciais do *Encoder* alinham estruturas léxico-sintáticas (idioma), enquanto as camadas mais profundas abstraem a semântica e a tarefa final. Em ambientes de entrega rápida e e-commerce, o vocabulário e a intenção do usuário variam drasticamente entre avaliar a qualidade intrínseca de uma mercadoria e avaliar o serviço de roteirização e entrega da transportadora.

4. A Lacuna (The Gap)

Embora a literatura confirme que o *Domain Shift* prejudica classificadores de texto, há uma escassez de estudos empíricos que isolem o impacto estrutural simultâneo entre idioma e domínio em modelos multilíngues. A lacuna reside em não sabermos exatamente como a manipulação do grafo computacional (especificamente, o bloqueio do *backpropagation* em extratos específicos da rede através do *Layer Freezing*) pode forçar o modelo a desembaraçar (*disentangle*) a representação da linguagem da representação do contexto logístico, otimizando o *fine-tuning* sem a necessidade de rotular novos dados.

5. Datasets

Para isolar as variáveis, os dados devem abranger os dois idiomas e os dois domínios, formando cruzamentos exatos. As bases serão filtradas via palavras-chave simples para separar avaliações focadas na "Mercadoria" daquelas focadas na "Entrega/Logística".

- **Dataset de Origem (Treino e Validação em Inglês):**
 - **Amazon Customer Reviews Dataset** (disponível no Hugging Face/Kaggle). Possui milhões de avaliações, permitindo extrair subconjuntos claros focados no produto e focados em problemas de *shipping/delivery*.
- **Dataset de Destino (Teste *Zero-Shot* em Português):**
 - **Olist E-commerce Dataset** ou **Corpus B2W-Reviews** (ambos disponíveis no Kaggle). Contêm o jargão brasileiro coloquial de internet, ideal para testar

tanto a avaliação do produto quanto a avaliação da logística e motoristas parceiros.

6. Métodos

A implementação técnica focará no controle da arquitetura durante o treinamento.

- **Arquitetura-Alvo:** XLM-RoBERTa (modelo base pré-treinado carregado via biblioteca `transformers`).
- **Pipeline de Treinamento (*Fine-Tuning*):** O modelo receberá uma camada densa de classificação (*classification head*). O treinamento utilizará a função de custo *Cross-Entropy Loss* e o otimizador AdamW.
- **Mecânica de Congelamento (*Layer Freezing*):** Serão executados ciclos de treinamento alterando o atributo `trainable = False` nas camadas do *Encoder*. O experimento testará o congelamento das camadas iniciais (1 a 6) versus o congelamento das camadas finais (7 a 12).
- **Matriz de Experimentos (*Design de Isolamento*):** O modelo treinado estritamente em **Produto/Inglês** será testado em quatro cenários:
 1. *Target:* Produto/Inglês (Controle).
 2. *Target:* Produto/Português (Isola o *Language Shift*).
 3. *Target:* Logística/Inglês (Isola o *Domain Shift*).
 4. *Target:* Logística/Português (Impacto Simultâneo).
- **Métricas de Avaliação:** F1-Score (Macro) para lidar com o natural desbalanceamento das classes (predominância de notas altas e baixas) e análise gráfica das curvas de *Loss* para identificar o momento exato em que a rede perde a capacidade de generalização durante o cruzamento de domínios.
- **Ambiente de Desenvolvimento:** Construção dos *scripts* em Python utilizando IDEs modernas para prototipação (VS Code/Cursor) e execução do processamento de tensores acelerado por GPU (Google Colab).

Esse formato entrega exatamente o que um professor de Inteligência Artificial espera: clareza no problema, domínio das ferramentas e uma metodologia de engenharia rigorosa para provar a hipótese.